ЛАБОРАТОРИЯ СБЕРИНДЕКС · КОНКУРС 2026 · ТРЕК «ПРОГНОЗИРОВАНИЕ»

Сдвиг в тратах муниципалитета нельзя предсказать заранее. Но его можно обнаружить за месяц

Мы измерили границы предсказуемости на 2 016 муниципалитетах России и разделили решение на два контура: рабочий прогноз базового тренда с калиброванными интервалами и оперативный мониторинг аномалий с контролем ложных тревог.

1 322 ₽ / чел.
MAE чемпиона на «Все категории» (h=1) — точнее Prophet на всех горизонтах (RelMAE 0.324 vs 0.460, −34% ошибки)

1.48 п.п. MAE форварда
прогноз на 2025-H1 против официального ряда СберИндекса (+13.3% vs факт +14.5%, в 2.0× точнее бенчмарка 2024 г.)

88–94% надёжность
фактическое покрытие 80% интервалов прогноза с Mondrian-калибровкой для малых МО



МЕДИАННЫЕ РАСХОДЫ ПО 2 016 МО, «ВСЕ КАТЕГОРИИ», 24 МЕСЯЦА · декабрьские пики ×1.19…×1.46 · годовой тренд +15.1%

панель 2 016 МО × 24 мес × 6 категорий · 20 моделей · 6 методов детекции · 27 806 новостей · независимый аудит и тесты

СБЕРИНДЕКС · 2026

Семь гипотез: эмпирическая проверка отделяет устойчивые эффекты от скрытого переобучения

ГИПОТЕЗА	КАК ПРОВЕРЯЛИ	ЧТО ВЫШЛО
Годовой дрейф +15% ломает сезонный наивный прогноз	поправка на панельный темп роста; скользящая expanding-сетка	ДА чемпион сводной категории точнее Prophet на всех горизонтах (слайд 5)
Prophet силён при явной годовой сезонности	три конфигурации; на 24 мес требуется явный yearly_seasonality=True	ДА Prophet-B* — сильнейший бейзлайн пула; соревнуемся только с ним
Foundation-модели выиграют на коротких рядах	Chronos-2 и TimesFM 2.5 zero-shot + внешние макро-ковариаты	ЧАСТИЧНО по ошибке уступают статистике; дают валидные интервалы (94%) (слайд 7)
Новости улучшат числовой прогноз	27 806 заголовков; пошаговая абляция тематических слоев N0→N3	ОТКЛОНЕНО макро-тексты дают шум (+11…+21% к MAE); переведены в детекцию (слайд 11)
Шок можно предсказать заранее	три механизма: автодорожные соседи, панельный радар, refit-от-брейка	ОТКЛОНЕНО на месячной сетке сигнал отсутствует; работает детекция за 0–1 мес (слайд 10)
Сложный ансамбль превзойдет одиночную модель	проверка на отложенных периодах (holdout origins); веса только по ранним	ОТКЛОНЕНО in-sample выигрыш (−22%) оборачивается деградацией (+46.5%) (слайд 6)
Прогноз сохранит точность за пределами выборки	форвард-2025 против независимого официального ряда Лаборатории	ДА MAE 1.48 п.п., факт внутри 80%-полосы во всех 6 месяцах (слайд 13)

Методологическая гигиена: отказ от пост-хок подгонки ансамблей · использование симметричной MAE вместо искажающей sMAPE · исключение NC-лицензий (Moirai-2, TimesFM 3.0) · строгая проверка на отложенных срезах.

2 016 муниципалитетов России и 2 года трат: панель трекает официальный ряд (r = 0.955)

140 184

тестовые matched-ячейки бэктеста — все модели сравнены в строго идентичных условиях (ряд × origin × шаг)

2 016

муниципалитетов с полной историей 2023–2024 (100% покрытие целевой выборки)

24 × 6

месяца (2023-01–2024-12) × категорий трат, ₽/жителя в месяц

27 806

новостных заголовков деловых медиа («Коммерсантъ», «Ведомости»)

МЕДИАННЫЕ РАСХОДЫ ПО 2 016 МО, «ВСЕ КАТЕГОРИИ», ₽/ЖИТЕЛЯ — 24 МЕСЯЦА

декабрьские пики ×1.19…×1.46 · номинальный тренд +15.1%

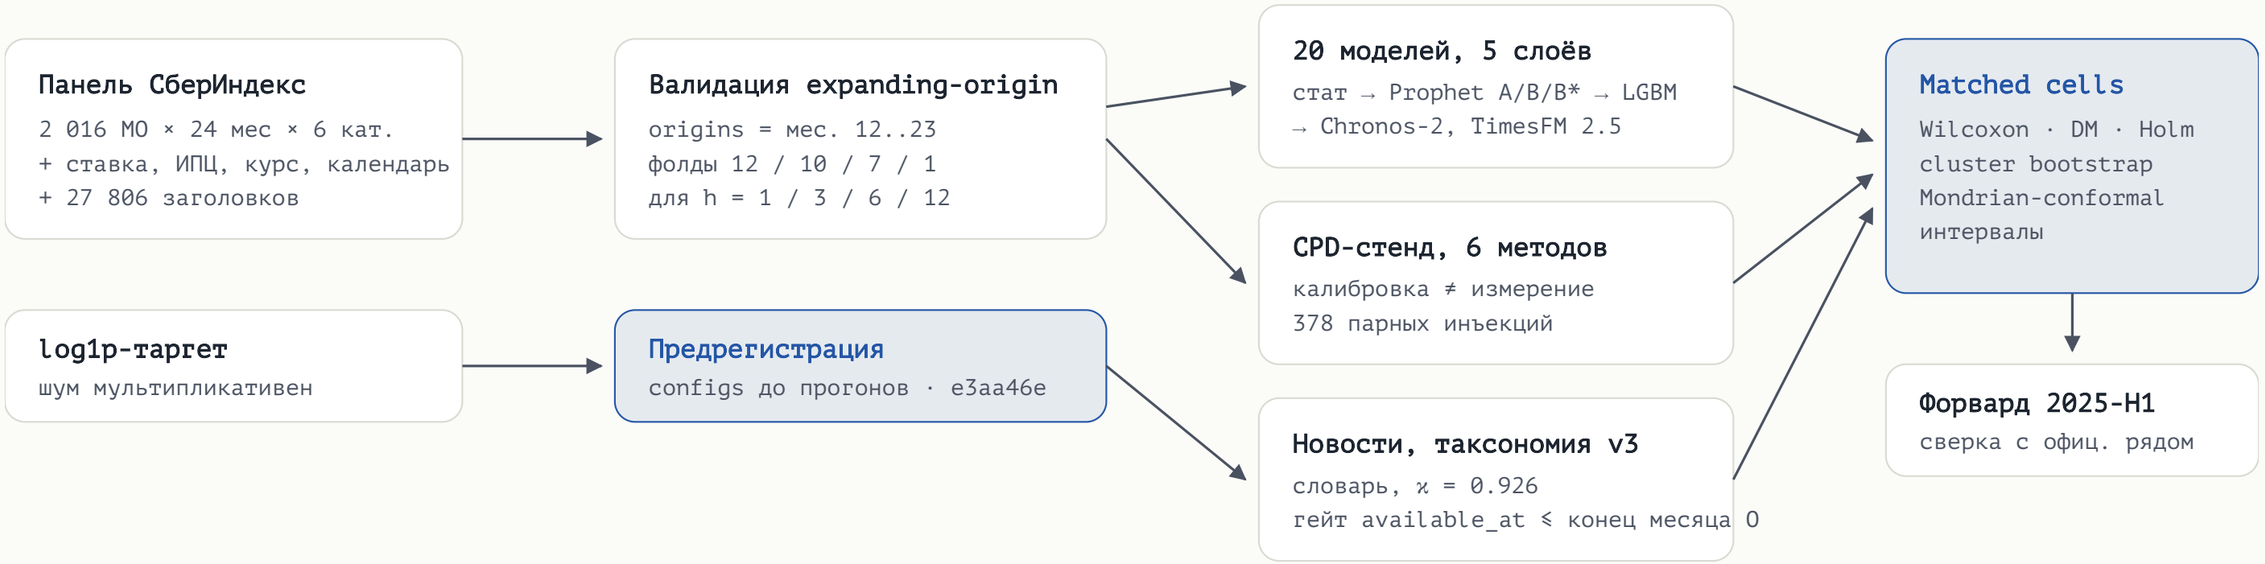


Все величины — номинальные рубли; ценовой и объёмный сдвиги различаем по контексту ИПЦ, не по знаку ряда. Внешние ряды: ставка и ИПЦ ЦБ РФ, курс USD/RUB, производственный календарь.

ДАННЫЕ

Архитектура конвейера: от сырых транзакций к управленческим инсайтам

Единая скользящая expanding-origin валидация: модели обучаются строго на прошлом, тест в будущем · сравнение на едином matched пересечении ячеек



ВОСПРОИЗВОДИМОСТЬ

make reproduce (~9–11 ч) · MANIFEST.sha256 входов · decision.json — реестр гейтов · 5 сидов LGBM · tests 22/22

АРХИТЕКТУРА

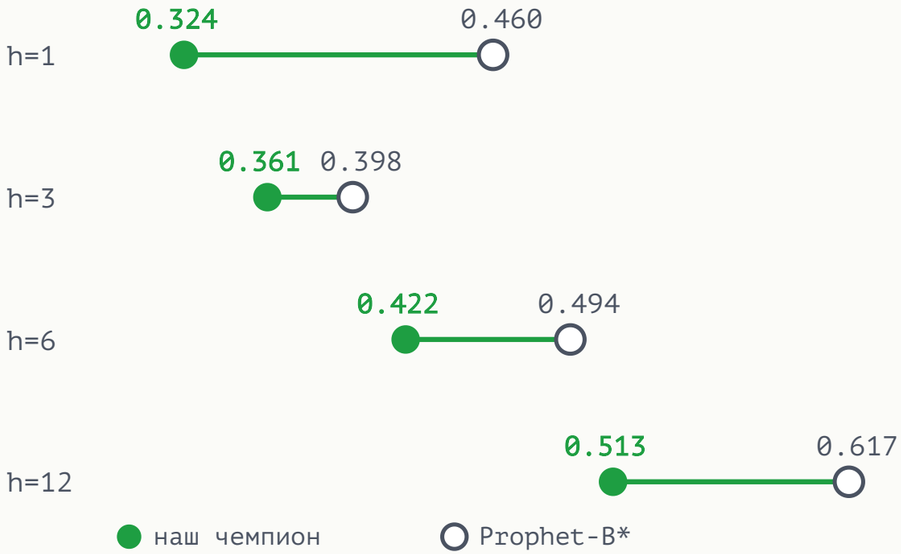
Сравнение моделей: разделение лидерства по уровню агрегации

ГОРИЗОНТ	НАША МОДЕЛЬ	RELMAE	PROPHET-B*	Δ МЕДИАНЫ	N ФОЛДОВ
h = 1	DriftAdjSNaive	**0.324**	0.460	**−34%**	12
h = 3	DriftAdjSNaive	**0.361**	0.398	**−8%**	10
h = 6	DriftAdjSNaive	**0.422**	0.494	**−11%**	7
h = 12	SeasProfileHA	**0.513**	0.617	**−22%**	1

RelMAE — ошибка модели в долях от сезонного наивного («прогноз = как год назад») на тех же ячейках: 0.324 = втрое точнее наивного. На «Все категории» (h=1) MAE чемпиона — 1 322 ₽ против 1 877 ₽ у Prophet-B* (−555 ₽, −34% ошибки). Парный тест Wilcoxon по 2 016 рядам: значимо на всех 4 горизонтах ($p < 0.001$ с поправкой Holm). Чемпионы — адаптивные эвристики без долгого обучения: DriftAdjSNaive = сезонный наивный + поправка на дрейф панели; SeasProfileHA = иерархический сезонный профиль категории × уровень МО.

Разделение по уровням. На полном пуле 6 категорий сильнейшим остаётся Prophet с включённой годовой сезонностью (Prophet-B*: 0.457/0.412/0.521/0.626; pooled MAE 597 ₽ против 635 ₽): преимущество подтверждено измерением. На 24-месячной истории yearly_seasonality в Prophet требует явного включения — мы активировали её, сформировав сильнейший бейзлайн.

НАШ ЧЕМПИОН vs PROPHET-B* — «ВСЕ КАТЕГОРИИ», RELMAE



Робастность и себестоимость внедрения

Себестоимость: чемпион считается за 2 сек. без обучения (0 GPU) vs 3.2 ч у Prophet-B* · sliding-18: отрыв растёт (0.249 vs 0.440) · bootstrap CI −608 ₽ [−669; −549] · специализация: на Маркетплейсах (+54%/год) побеждает LightGBM+news (0.281 / 468 ₽), на Здоровье — TimesFM 2.5 (93 ₽)

outputs/T1 · T2_slice_category · T3_significance · robustness_*.csv — matched cells, 140 184 ячейки на h=1

ЗАЩИТА ОТ ПЕРЕОБУЧЕНИЯ НА ПРАКТИКЕ · K1 · K2

Ансамблирование на коротких рядах: почему мы остановились на устойчивой одиночной модели

−22%

бленд DriftAdj + Prophet-B* на полной ретроспективе — иллюзия выигрыша при подборе задним числом (in-sample)

→

+46.5%

та же конструкция на отложенных срезах (out-of-sample): режимы между годами неоднородны, «выигрыш» оборачивается ухудшением ошибки

Гейт включения энсембля зафиксирован в configs/champion.yaml до прогонов: требовалось устойчивое улучшение ΔMAE ≤ −1% на отложенных срезах. Ни одна из 8 проверенных комбинаций его не прошла. Робастность одиночной адаптивной модели надёжнее защищает промышленную эксплуатацию от скрытого переобучения.

ДИСЦИПЛИНА

outputs/rc1_o1_*.csv · block bootstrap по 73 регионам, 1000 реплик · scripts/rc1_o1_*.py

K1 · K2 · гейт: configs/champion.yaml

Chronos-2 и TimesFM 2.5 на 24 точках: карта применимости — измерено в обе стороны

ДА Что работает

- **Ковариаты** (региональный прирост и ставка ЦБ): ΔRelMAE −0.04/−0.08/−0.08 на h=1/3/6, win rate 60–64%
- **Квантили из коробки** валидны на h≥2: фактическое покрытие 94% при номинале 80% (обещали 4 из 5 — получили 94 из 100)
- **Интерпретируемость**: адекватный отклик траекторий на сдвиги макро-параметров
- **Скорость**: вся панель Chronos-2 рассчитывается за ~16 мин на MPS

НЕТ Что не подтвердилось

- **По MAE уступают классическим моделям**: zero-shot Chronos-2 (0.515) — 12-я из 20 на h=1; с ковариатами (0.472) — 6-я; Prophet-B* 0.457
- **Холодный старт** (9 новых МО): паритет с базовым Naive, RelMAE 1.03
- **Короткий ряд**: потенциал длинного контекста 8 192 точек физически не задействован на 24 месяцах

Почему так — и что это стоит

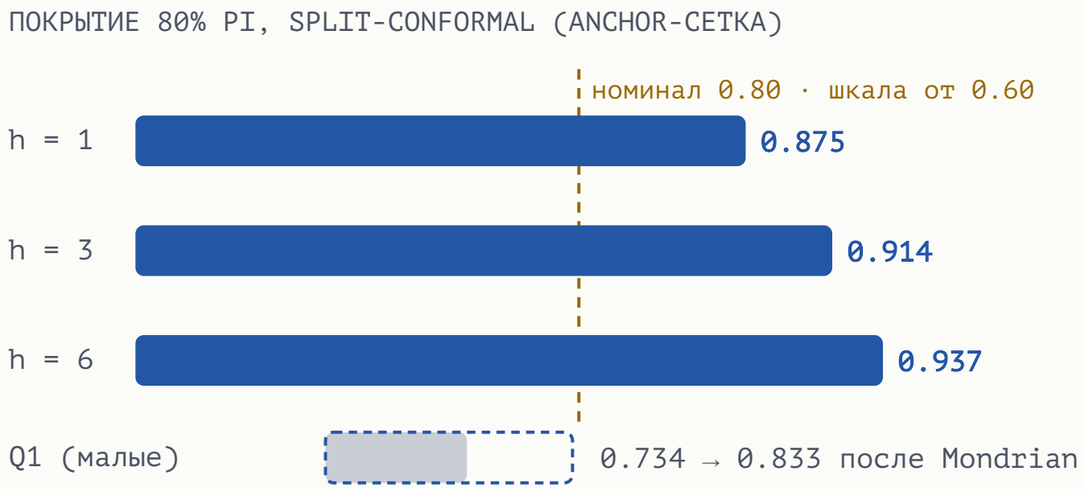
Контекст современных TSFM рассчитан на тысячи точек; на 24 месячных наблюдениях преимущество длинной памяти не работает. Это согласуется с внешними бенчмарками (GIFT-Eval: паритет AutoARIMA и нейросетей на monthly). **Вычислительная цена:** чемпион считается секунды без обучения · Prophet-B* ~3.2 ч · Chronos-2 ~16 мин на MPS · TimesFM ~3.3 ч CPU. Модели с non-commercial лицензиями исключены по регламенту.

ПРАКТИЧЕСКИЙ ВЫВОД ДЛЯ ЛАБОРАТОРИИ: на месячных муниципальных панелях тяжелые нейросети уступают надежной классической статистике. Их ниша — длинные высокочастотные ряды

preds_chronos2_* · preds_timesfm25_zs_log · coldstart_chronos.csv · rc1_o3_tsfm_ensemble.csv · cost_timings.csv

Точность в рублях и надёжные коридоры риска: чемпион h=1 даёт 1 322 ₽; интервалы валидны (0.875–0.937)

- **MAE (₽) — абсолютная ошибка трат**: на сводной категории «Все категории» чемпион даёт 1 322 ₽ против 1 877 ₽ у Prophet-B* (−555 ₽); на полном пуле 6 категорий — 635 ₽ против 597 ₽ (оба среза показаны открыто)
- **Масштаб ошибки**: median nMAE = 0.078 — ошибка составляет всего ~5–8% от медианных месячных трат жителя · RelMAE — сопоставимость между категориями
- **Исключение искажающих метрик**: sMAPE исключена из-за внутренней асимметрии штрафа; MAPE не определена при околонулевых тратах малых территорий
- **Учёт асимметричной цены ошибки**: если недопрогноз критичнее перепрогноза, калибровка квантиля прошлых остатков снижает потери на 20–34% без переобучения модели



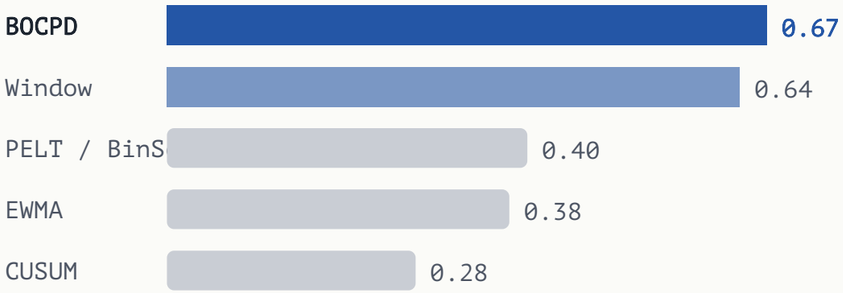
Коридоры неопределённости построены конформным методом (split-conformal) без предположений о нормальности шума. Адаптивная калибровка Mondrian защитила малые МО от недопокрытия (0.734 → 0.833), при этом медианная ширина коридора даже сократилась на −3.1% (калибровка без раздувания интервалов).

КАЛЕНДАРЬ РИСКА: в декабре система автоматически флагает **82.6%** территорий как волатильные, заблаговременно расширяя коридор неопределённости под новогодний пик

configs/validation.yaml · outputs/intervals_coverage.csv · rc1_o8_linlin.csv · T1_model_x_horizon.csv

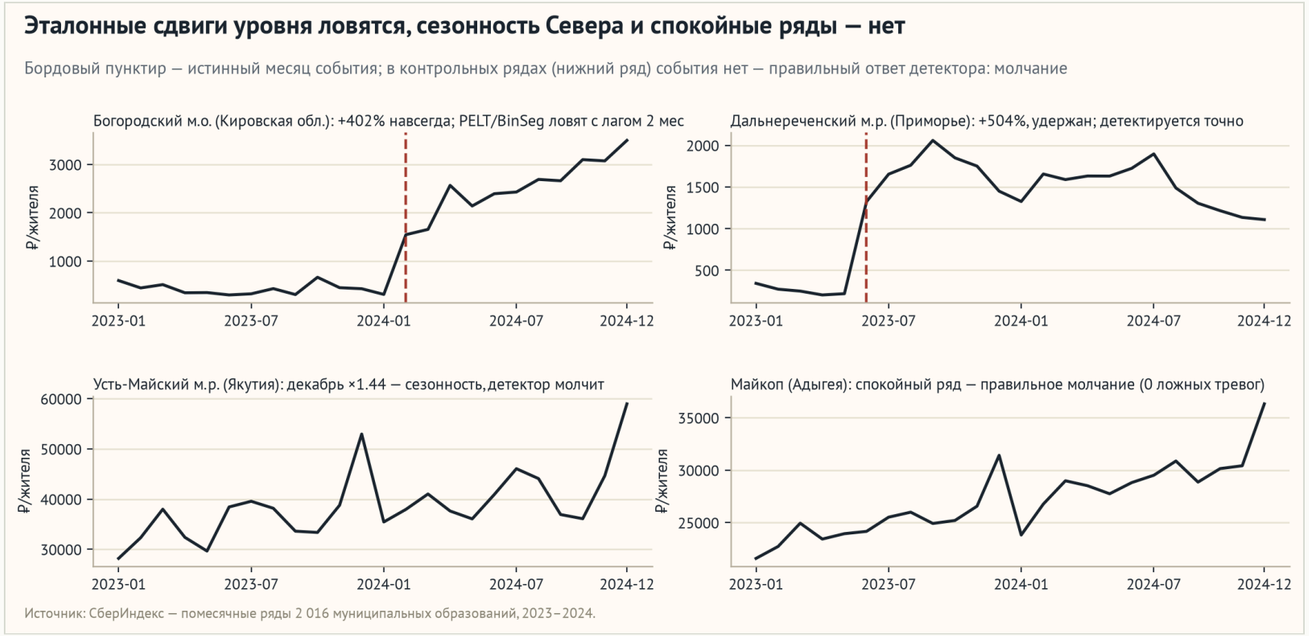
Детекция структурных сдвигов: калибровка в условиях жесткого бюджета ложных тревог

MATCHED-RATE F1 · равный бюджет срабатываний всем



голосование «≥2 из 3» уступает BOCPD-одиночке в 10/10 ячеек

- **Приоритет чистоты сигнала**: в масштабе 2 016 МО ложная тревога стоит дорого (ручной аудит). При жестком лимите FAR ≤ 2/1000 (~4 сигнала в мес на страну) BOCPD дал лучший F1 (0.67 против 0.40 у PELT). В рабочей зоне (FAR ~15/1000) полнота достигает 47%.
- **Разделение калибровки и теста**: проверено на 11 304 / 378 инъекциях сдвигов уровня; рабочая точка выбрана из баланса цены ложной тревоги к пропуску.
- **Фильтрация сезонности**: предобработка полностью снимает ложные январские срабатывания (0.0% у PELT/BinSeg против 64% у наивной нормировки).



СЛЕВА: Богородский м.о. · Маркетплейсы (+402%) · СПРАВА: Дальнереченский м.р. · Общепит (+504%)

Реальные тектонические сдвиги уровня надёжно фиксируются с лагом 0–2 мес (пунктир — брейки PELT/BinSeg): Богородский +402%, Дальнереченский +504%. Refit-от-брейка не улучшает числовой прогноз (ΔMAE +1.1%): задача детектора — оперативный мониторинг и объяснение, а не переобучение.

outputs/cpd_frontier_v2.csv · cpd_matched_rate_v3.csv · rc1_o4_*.csv · src/cpd.py

Физические границы опережения: почему шоки требуют быстрого реагирования, а не предсказания

МЕХАНИЗМ 1 · ПРОСТРАНСТВО

1.08

лифт у соседей ≤ 80 км = 1.08 — сдвиги рядом лишь на 8% чаще случайного (p = 0.77; 42 404 пары). Потребительские шоки локальны и не распространяются волной по дорожной сети.

МЕХАНИЗМ 2 · ПАНЕЛЬНЫЙ РАДАР

0.049

PR-AUC 0.049 при фоновой доле событий 0.048: на месячном шаге ранние маркеры сглаживаются, заблаговременный сигнал за 30 дней неотличим от шума.

МЕХАНИЗМ 3 · REFIT ОТ БРЕЙКА

+1.1%

сброс обучающего окна после брейка ухудшает прогноз: ΔMAE +1.1% — на коротких рядах сохранение объема выборки важнее отсечения режима.

ЧТО РАБОТАЕТ НА ПРАКТИКЕ ДЛЯ ОПЕРЕЖЕНИЯ:

- быстрая детекция 0–1 мес — на 45–60 дней быстрее релизов Росстата
- новостная интерпретация до закрытия месяца
- декабрьское расширение интервалов

КОНТРОЛИ ПРОТОКОЛА: якутские декабри (ложная сезонная тревога) — 0.0% у PELT/BinSeg после предобработки · штиль-месяцы без событий — детектор молчит · авто-ажиотаж 2022 вне окна данных

ЧЕСТНЫЕ ГРАНИЦЫ

Новостной поток (27 806 заголовков): функциональное разделение прогноза и аналитики

Механизм таксономии

- 6 макро-индексов: цены, курс, ставка, санкции, настроения, ЧС — каждый с экономическим смыслом
- Контролируемый словарь с мультилейблом — полностью прозрачен, без чёрного ящика; κ = согласие с экспертной ручной разметкой: **0.926** (активные темы 0.85–1.00, n=50)
- Строгая временная отсечка: as-of join структурно гарантирует доступность новости ≤ конца месяца origin'a

Числовой прогноз

- Абляция слоёв N0→N3: `+10.8 / +15.9 / +20.7%` к MAE (h=1) — макро-новости создают избыточный шум на коротких рядах
- Зафиксированное правило отбора защитило модель от включения переобучающего слоя
- Исключение: на быстрорастущих Маркетплейсах LGBM+news показал минимальную ошибку панели (RelMAE 0.281)

Аналитика и детекция

- Матрица всплесков медиа × PELT: сопоставление аномалий с новостями надёжно разделяет национальные и локальные шоки
- Временно́е плацебо (×100 000, p = 0.84): подтверждает, что новости — инструмент качественной интерпретации, а не числовой предиктор
- Примеры совпадений: ставка 21% в окт-2024, ЧС паводков в апр-2024

СЛОВАРЬ ЧИТАЕТСЯ ГЛАЗАМИ: цены → «Годовая инфляция в России за неделю ускорилась до 8,61%» (Коммерсантъ, 30.10.2024) · ЧС → «В Курганской области введен режим ЧС в связи с пожарами» (Ведомости, 28.04.2023) · все 6 тем × 3 заголовка: outputs/news_theme_headlines.md

Практическая ценность: три ключевых инсайта о потреблении в регионах России

Маркетплейс-волна — сдвиги уровня, не тренд

+402%

Богородский м.о. (Кировская обл.), 2024-02: 308 → 1545 ₽/жителя, уровень удержан до конца панели (доля 2.5% → 13.4%). Дальнереченский (Приморье): +504%, 19 мес.



Доверие: алгоритмы PELT/BinSeg ловят с лагом 0–2 мес; сумма категорий сходится — реальное переключение канала трат

Сезонность — четыре календаря

×1.54

декабрь у Маркетплейсов (Продовольствие ×1.19, Общепит — июль ×1.21, Транспорт — август ×1.10); амплитуда декабря по МО 1.08–1.46, максимум — Север (Усть-Майский)

Глобальный календарь на Севере ошибается вдвое; покатегорийные профили чемпионов учитывают эту региональную дифференциацию

Номинал ≠ реал

+5–6%

реальный рост при номинале +15.1% и ИПЦ 9.5%; после дефляции панель даёт +6.2% — против официального реального ряда 4.6–6.7%

Двойная сверка эталона (помесячная и недельная серии) позволила выявить методологический слом в официальном ряде Общепита (+34 п.п. разрыва)

ИСПОЛЬЗОВАНИЕ ДЛЯ БАНКА И РЕГИОНОВ: ежемесячная витрина «переключившиеся территории» (мониторинг проникновения e-commerce) · библиотека сезонных профилей для управления ликвидностью · двухсерийная верификация эталона (защита от сломов статистики)

outputs/cpd_breaks_v2.parquet · external_real_growth.csv · external_obshchepit_gap.csv · §7 отчёта — шесть находок по триаде

Форвард-валидация на 2025-H1: MAE 1.48 п.п. против официального ряда Лаборатории

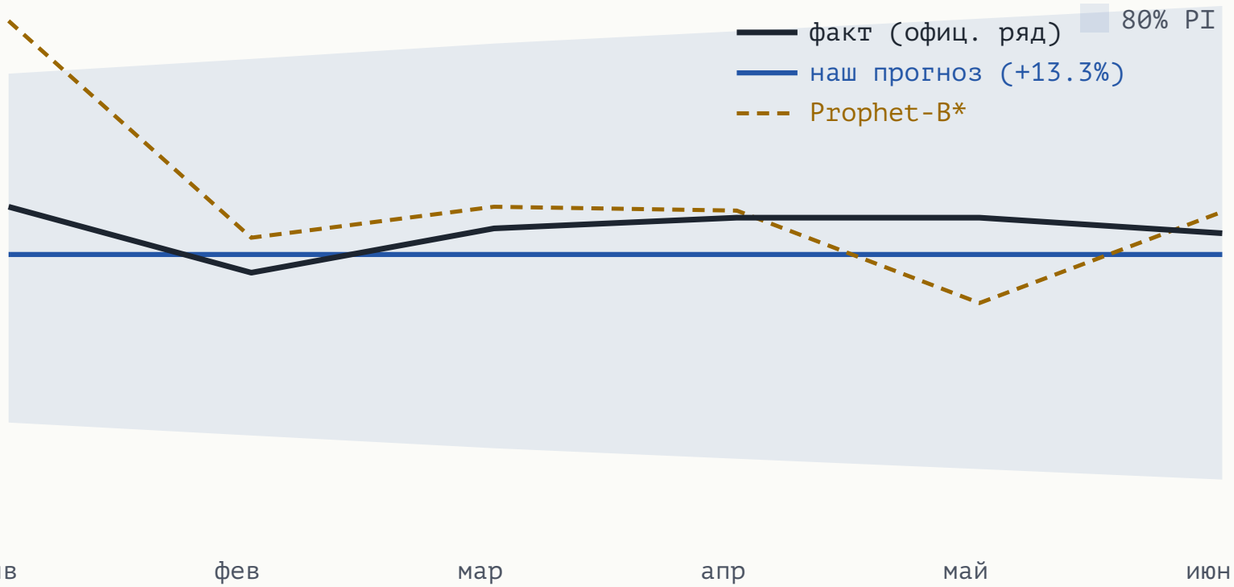
1.48 п.п.

MAE чемпиона (DriftAdjSNaive) относительно официального ряда Лаборатории на агрегате «Все категории» · факт удержан внутри 80%-полосы во всех 6 месяцах (6 из 6) · Продовольствие: 1.36 п.п.

Сравнение: Prophet-B* на тех же данных показал ошибку 2.83 п.п. (Продовольствие 4.25) — выигрыш 2.0x за пределами train.

Ответственный риск-контроль: горизонт H2 отозван из публикации — бэктест-чемпион h=12 провалил форвард-контроль (MAE 28.0 п.п. на янв-2025). Публикуется только 100% валидированный H1.

РОСТ г/г, % · 2025-01…06 · ФАКТ vs ПРОГНОЗ vs PROPHET-B*



Прогноз базового тренда (+13.3% г/г) точно описал динамику стабильных категорий при факте +14.5% (смещение −1.2 п.п.). Специфика Общепита: в начале 2025 года в официальной статистике произошла структурная перекалибровка учета (+52.7% г/г), вызванная институциональным обелением сектора, а не плавным ростом спроса.

ОГРАНИЧЕНИЯ · ВОСПРОИЗВОДИМОСТЬ · K1

Методологические границы и гарантии воспроизводимости: все результаты проверяются одной командой

Объективные границы данных и методов

- **Длина панели 24 месяца**: один годовой цикл; на горизонте h=12 статистическая мощность обеспечивается пространственной выборкой (2 016 МО), а не временной глубиной
- **Границы Foundation-моделей**: архитектуры класса Chronos/TimesFM оптимизированы под длинные контексты; на 24 точках оптимум остаётся за калиброванной статистикой
- **Фокус мониторинга**: задача раннего предупреждения решается как оперативный мониторинг с минимальным лагом (0–1 мес), а не заблаговременное предсказание шоков

При расширении истории до 36 месяцев станет доступна прямая оценка временной динамики h=12 и расширенные окна адаптации.

`make verify` · <1 сек · мгновенная валидация всех витрин

`make reproduce (~9-11 ч)` `MANIFEST.sha256 входов`

`number_index.md — число → команда` `decision.json — журнал решений`

`tests 22/22` `LGBM 5 сидов ±0.009`

Публичный репозиторий: код, тесты, витрины. Отчёт: reports/methodology.md · презентация: reports/presentation.pdf

ГРАНИЦЫ · ВОСПРОИЗВОДИМОСТЬ